

San Francisco Salaries

```
In [2]: import pandas as pd
```

Erstelle aus salaries.csv einen DataFrame

```
In [ ]: sal = pd.read_csv("./salaries.csv", low_memory=False, na_values=['Not Provided'])
for col in ['BasePay', 'OvertimePay', 'OtherPay', 'Benefits', 'TotalPay', 'TotalPayBasis']:
    sal[col] = pd.to_numeric(sal[col], errors='coerce')
sal['Year'] = pd.to_numeric(sal['Year'], errors='coerce')

sal.shape
```

```
Out[ ]: (148654, 13)
```

**** Empfohlen: head() ****

```
In [4]: # Empfohlen: head()
sal.head()
```

```
Out[4]:
```

	Id	EmployeeName	JobTitle	BasePay	OvertimePay	OtherPay	Benefits
0	1	NATHANIEL FORD	GENERAL MANAGER-METROPOLITAN TRANSIT AUTHORITY	167411.18	0.00	400184.25	NaN
1	2	GARY JIMENEZ	CAPTAIN III (POLICE DEPARTMENT)	155966.02	245131.88	137811.38	NaN
2	3	ALBERT PARDINI	CAPTAIN III (POLICE DEPARTMENT)	212739.13	106088.18	16452.60	NaN
3	4	CHRISTOPHER CHONG	WIRE ROPE CABLE MAINTENANCE MECHANIC	77916.00	56120.71	198306.90	NaN
4	5	PATRICK GARDNER	DEPUTY CHIEF OF DEPARTMENT, (FIRE DEPARTMENT)	134401.60	9737.00	182234.59	NaN

Wie viele Observations gibt es?

```
In [5]: # Wie viele Observations gibt es?
```

```
sal.shape[0]
```

Out[5]: 148654

Was ist das arithmetische Mittel von BasePay?

Lösung: 66325.44884050643

```
In [6]: # Arithmetisches Mittel von BasePay  
sal['BasePay'].mean()
```

Out[6]: np.float64(66325.44884048769)

Was ist der höchste Geldbetrag, der als OvertimePay vorhanden ist?

Lösung: 245131.88

```
In [7]: # Höchster Betrag in OvertimePay  
sal['OvertimePay'].max()
```

Out[7]: 245131.88

Welchen Job hat JOSEPH DRISCOLL? (Nicht Joseph Driscoll).

Lösung:

CAPTAIN, FIRE SUPPRESSION

```
In [8]: # Welchen Job hat JOSEPH DRISCOLL? (Großschreibung wie im Datensatz)  
sal.loc[sal['EmployeeName']=='JOSEPH DRISCOLL', 'JobTitle'].iloc[0]
```

Out[8]: 'CAPTAIN, FIRE SUPPRESSION'

Was ist das Gesamtgehalt von JOSEPH DRISCOLL?

Lösung:

270324.91

```
In [9]: # Gesamtgehalt von JOSEPH DRISCOLL (TotalPay)  
sal.loc[sal['EmployeeName']=='JOSEPH DRISCOLL', 'TotalPay'].iloc[0]
```

Out[9]: np.float64(270324.91)

Wie lautet der Name der bestverdienenden Person?

Lösung: NATHANIEL FORD

```
In [10]: # Name der bestverdiensten Person (nach TotalPayBenefits)
sal.loc[sal['TotalPayBenefits'].idxmax(), 'EmployeeName']
```

Out[10]: 'NATHANIEL FORD'

Wie lautet der Name der am schlechtest bezahlten Person?

Lösung: Joe Lopez

```
In [11]: # Name der am schlechtest bezahlten Person (nach TotalPayBenefits)
sal.loc[sal['TotalPayBenefits'].idxmin(), 'EmployeeName']
```

Out[11]: 'Joe Lopez'

Ermittle für die Jahre 2012-2014 den arithmetischen Mittelwert des BasePay s aller Personen.

Lösung:

Year	
2012	65436.406857
2013	69630.030216
2014	66564.421924

```
In [12]: # Arithmetisches Mittel des BasePay für die Jahre 2012-2014
sal.groupby('Year')['BasePay'].mean().loc[[2012,2013,2014]]
```

```
Out[12]: Year
2012    65436.406857
2013    69630.030216
2014    66564.421924
Name: BasePay, dtype: float64
```

Wie viele unterschiedliche Jobs gibt es?

Lösung: 2159

```
In [13]: # Wie viele unterschiedliche Jobs gibt es?
sal['JobTitle'].nunique()
```

Out[13]: 2159

Welche sind die Top 5 häufigsten Jobs und wie viele gibt es davon jeweils?

Lösung:

Transit Operator	7036
Special Nurse	4389
Registered Nurse	3736
Public Svc Aide-Public Works	2518
Police Officer 3	2421

Name: JobTitle, dtype: int64

```
In [14]: # Top 5 häufigsten Jobs und Anzahl
sal['JobTitle'].value_counts().head(5)
```

```
Out[14]: JobTitle
Transit Operator      7036
Special Nurse         4389
Registered Nurse      3736
Public Svc Aide-Public Works  2518
Police Officer 3      2421
Name: count, dtype: int64
```

Wie viele Jobs gibt es, die 2013 nur eine Person ausübte?

Lösung: 202

```
In [15]: # Wie viele Jobs gab es 2013, die nur eine Person ausübte?
counts_2013 = sal[sal['Year']==2013]['JobTitle'].value_counts()
(counts_2013==1).sum()
```

```
Out[15]: np.int64(202)
```

Wie viele Personen haben 'chief' (caseinsensitive) im Jobnamen?

Lösung: 627

```
In [16]: # Wie viele Personen haben 'chief' (case-insensitive) im Jobnamen?
sal['JobTitle'].str.contains('chief', case=False, na=False).sum()
```

```
Out[16]: np.int64(627)
```

```
In [17]: %matplotlib inline
import matplotlib.pyplot as plt
# Histogramm des BasePay (nur gültige Werte)
plt.figure(figsize=(10,5))
sal['BasePay'].dropna().hist(bins=50)
plt.title('Histogram of BasePay')
plt.xlabel('BasePay')
plt.ylabel('Count')
plt.show()
```

